گزارش تمرین برنامه‌نویسی

مدل زبانی N-gram برای تکمیل قطعات موسیقی

پردازش زبان طبیعی — مدل‌سازی آماری

۱. معرفی کد پایتون و ساختار کلی برنامه

برنامه در چهار بخش اصلی سازماندهی شده است:

- **بارگذاری و پیش‌پردازش داده‌ها:** خواندن CSV، تبدیل رشته نت‌ها به لیست توکن و پشتیبانی از حذف علائم تغییردهنده.
- **کلاس NGramModel**: پیاده‌سازی مدل N-gram با هموارسازی Lidstone، آموزش، محاسبه احتمال لگاریتمی و تکمیل دنباله.
- **تابع perplexity**: محاسبه سرگشتگی برای ارزیابی کیفیت مدل.
- **بهینه‌یابی α**: جستجو با Leave-One-Out Cross-Validation.

۳. روش بهینه‌یابی α

برای یافتن بهینه‌ترین مقدار alpha از روش Leave-One-Out Cross-Validation (LOO-CV) استفاده شده است:

مدل	بهترین α	میانگین Perplexity (بهینه‌یابی CV)
Unigram	۵.۰	۱۱.۰۳۴۴
Bigram	۱.۰	۸.۴۵۲۵
Trigram	۰.۷	۹.۲۸۵۷

۴. نتایج تکمیل قطعات موسیقی

Unigram — با علائم تغییردهنده

Laplace (α=۱):

قطعه	پیشوند داده شده	ادامه تولید شده	Perplexity
۱	S S S S	C C C C C C C C C C	۶.۵۴۷۹
۲	G C G C	C C C C C C C C C C	۵.۵۲۲۸
۳	C B C D	C C C C C C C C C C	۵.۸۸۹۳
۴	A Bb C D	C C C C C C C C C C	۶.۲۶۱۸

قطعه	پیشوند داده شده	ادامه تولید شده	Perplexity
۵	A S B Db	C C C C C C C C C C	۹.۹۵۵۲

Jeffreys-Perks (α=۰.۵)

قطعه	پیشوند داده شده	ادامه تولید شده	Perplexity
۱	S S S S	C C C C C C C C C C	۶.۵۲۸۴
۲	G C G C	C C C C C C C C C C	۵.۵۰۳۰
۳	C B C D	C C C C C C C C C C	۵.۸۷۰۴
۴	A Bb C D	C C C C C C C C C C	۶.۲۴۳۱
۵	A S B Db	C C C C C C C C C C	۱۰.۴۳۱۸

Bigram — با علائم تغییردهنده

Laplace (α=۱)

قطعه	پیشوند داده شده	ادامه تولید شده	Perplexity
۱	S S S S	D C C C C C C C C C	۴.۵۸۱۶
۲	G C G C	C C C C C C C C C C	۵.۰۵۳۸
۳	C B C D	C C C C C C C C C C	۳.۷۱۹۶
۴	A Bb C D	C C C C C C C C C C	۳.۶۴۷۷
۵	A S B Db	A G G G G G G G G G	۶.۸۳۵۷

Jeffreys-Perks (α=۰.۵)

قطعه	پیشوند داده شده	ادامه تولید شده	Perplexity
۱	S S S S	D C C C C C C C C C	۴.۴۷۷۸
۲	G C G C	C C C C C C C C C C	۴.۹۸۷۵

قطعه	پیشوند داده شده	ادامه تولید شده	Perplexity
۳	C B C D	C C C C C C C C C C	۳.۶۲۱۱
۴	A Bb C D	C C C C C C C C C C	۳.۵۴۹۱
۵	A S B Db	A G G G G G G G G G	۷.۰۰۳۵

Trigram — با علائم تغییردهنده

Laplace (α=۱):

قطعه	پیشوند داده شده	ادامه تولید شده	Perplexity
۱	S S S S	G S S G S S G S S G	۵.۱۴۷۱
۲	G C G C	C C C C C C C C C C	۳.۵۰۶۲
۳	C B C D	C D C D C D C D C D	۳.۹۴۳۵
۴	A Bb C D	C D C D C D C D C D	۴.۰۰۷۶
۵	A S B Db	A A G G F G F G F G	۵.۶۸۹۴

Jeffreys-Perks (α=۰.۵):

قطعه	پیشوند داده شده	ادامه تولید شده	Perplexity
۱	S S S S	G S S G S S G S S G	۴.۱۲۳۴
۲	G C G C	C C C C C C C C C C	۳.۲۸۵۵
۳	C B C D	C D C D C D C D C D	۳.۵۸۱۳
۴	A Bb C D	C D C D C D C D C D	۳.۶۳۰۹
۵	A S B Db	A A G G F G F G F G	۵.۲۸۷۹

جدول خلاصه Perplexity همه مدل‌ها

مدل	α	قطعه ۱	قطعه ۲	قطعه ۳	قطعه ۴	قطعه ۵
Unigram	۱.۰	۶.۵۴۷۹	۵.۵۲۲۸	۵.۸۸۹۳	۶.۲۶۱۸	۹.۹۵۵۲
Unigram	۰.۵	۶.۵۲۸۴	۵.۵۰۳۰	۵.۸۷۰۴	۶.۲۴۳۱	۱۰.۴۳۱۸
Bigram	۱.۰	۴.۵۸۱۶	۵.۰۵۳۸	۳.۷۱۹۶	۳.۶۴۷۷	۶.۸۳۵۷
Bigram	۰.۵	۴.۴۷۷۸	۴.۹۸۷۵	۳.۶۲۱۱	۳.۵۴۹۱	۷.۰۰۳۵
Trigram	۱.۰	۵.۱۴۷۱	۳.۵۰۶۲	۳.۹۴۳۵	۴.۰۰۷۶	۵.۶۸۹۴
Trigram	۰.۵	۴.۱۲۳۴	۳.۲۸۵۵	۳.۵۸۱۳	۳.۶۳۰۹	۵.۲۸۷۹

۵. پاسخ به سوالات تحلیلی

روش یافتن کمترین مقدار α و نحوه ارزیابی

برای یافتن بهینه‌ترین alpha از Leave-One-Out Cross-Validation (LOO-CV) استفاده می‌شود. در این رویکرد، مجموعه داده به ۴۱ تقسیم ممکن می‌شود. در هر تکرار، یک قطعه به‌عنوان داده آزمون کنار گذاشته شده و مدل بر روی ۴۰ قطعه باقی‌مانده آموزش می‌بیند. سپس Perplexity روی قطعه آزمون محاسبه و میانگین آن در تمام ۴۱ تکرار به دست می‌آید. این فرایند برای هر مقدار alpha کاندیدا تکرار می‌شود و alphaای که کمترین میانگین Perplexity را ایجاد می‌کند انتخاب می‌گردد.

دلیل انتخاب LOO-CV: با توجه به کوچک بودن مجموعه داده (۴۱ قطعه)، این روش حداکثر استفاده را از داده‌های موجود می‌برد و تخمین بی‌طرفانه‌تری از تعمیم‌پذیری مدل ارائه می‌دهد.

نتایج بهینه‌یابی:

- **Unigram (alpha = ۵.۰)**: مدل Unigram به هموارسازی شدید نیاز دارد چون هیچ اطلاعات زمینه‌ای ندارد.
- **Bigram (alpha = ۱.۰)**: تعادل مناسب بین داده‌های مشاهده‌شده و هموارسازی.
- **Trigram (alpha = ۰.۷)**: به هموارسازی کمتری نیاز دارد چون زمینه غنی‌تر اطلاعات بهتری می‌دهد، اما داده کم است پس مقدار خیلی کوچک هم مناسب نیست.

ارزیابی کیفیت با Perplexity

Perplexity (سرگشتگی) معیاری است که نشان می‌دهد مدل تا چه اندازه دنباله مشاهده‌شده را «غافلگیرکننده» می‌یابد .عدد کوچک‌تر به معنای مدل بهتر است (دنباله را بهتر پیش‌بینی می‌کند). از نتایج می‌توان دید که Trigram با alpha=۰.۵ در اکثر قطعات کمترین Perplexity را دارد.

روش ارزیابی پیشنهادی دیگر

با توجه به ذات موسیقیایی مسئله، ارزیابی بر اساس سازگاری با دستگاه موسیقی پیشنهاد می‌شود:

- هر دستگاه موسیقی ایرانی مجموعه خاصی از نت‌ها دارد (مثلاً دستگاه شور عمدتاً از نت‌های Bb, C, D, Eb, F, G, Ab استفاده می‌کند).

- می‌توان درصد نت‌های تولیدشده که با دستگاه پیش‌وند هم‌خوانی دارند را محاسبه کرد.
- این معیار جنبه موسیقیایی و شنیداری را نیز لحاظ می‌کند که Perplexity از آن غافل است.

دلیل پیشنهاد: Perplexity فقط احتمال آماری را ارزیابی می‌کند؛ یک قطعه موسیقیایی باید علاوه بر توزیع آماری، از نظر هارمونیک نیز منسجم باشد.

ترتیب عملکرد مدل‌ها

بر اساس نتایج Perplexity، ترتیب کلی از بهترین به ضعیف‌ترین به این شرح است: **Trigram > Bigram > Unigram**.

دلیل این ترتیب:

- **Unigram:** هیچ اطلاعاتی از زمینه (نت‌های قبلی) ندارد. تنها احتمال هر نت به صورت مستقل محاسبه می‌شود. در نتیجه همیشه رایج‌ترین نت (C) را تولید می‌کند و Perplexity بالاتری دارد.
- **Bigram:** با در نظر گرفتن یک نت قبلی، توالی‌های محتمل‌تری تولید می‌شود. مثلاً پس از S معمولاً D می‌آید که در موسیقی ایرانی رایج است.
- **Trigram:** با دو نت زمینه، الگوهای موسیقایی بهتری شناسایی می‌شوند. مثلاً پس از C–D، نت C مجدداً می‌آید که نشان‌دهنده الگوهای تکرارشونده در موسیقی ایرانی است.

(توجه: با وجود این که Trigram کمترین Perplexity را دارد، مشکل sparsity داده برای آن جدی‌تر است).

کدام مدل توزیع احتمالی بیانگرتر دارد؟

با مقایسه ضرایب هموارسازی:

- **alpha = ۰.۵ (Jeffreys–Perks):** در تمام مدل‌ها توزیع‌هایی تولید می‌کند که بیشتر بیانگر داده‌های واقعی هستند؛ چون هموارسازی کمتری به توکن‌های ندیده‌شده اختصاص می‌دهد و از این رو احتمالات بیشتری به توکن‌های پرکاربرد در داده داده می‌شود.
- **alpha = ۱.۰ (Laplace):** توزیع یکنواخت‌تری ایجاد می‌کند و بخشی از احتمال را به توکن‌هایی می‌دهد که در زمینه مربوطه هرگز در داده‌ها ظاهر نشده‌اند.

نتیجه: مدل Trigram با alpha = ۰.۵ بیشترین بیانگری از داده‌های موجود را دارد. با این حال، ریسک over-fitting و ناتوانی در تعمیم برای زمینه‌های دیده‌نشده در این مدل بیشتر است.

۶. نتایج بدون علائم تغییردهنده

تغییر واژگان

با حذف علائم تغییردهنده (b = بمل، k = کرن)، اندازه واژگان از ۱۴ به ۸ توکن کاهش یافت:

- **با علائم:** C، D، E، F، G، A، B، Bb، Ab، Eb، Ak، Dk، Bk، S (۱۴ توکن)
- **بدون علائم:** C، D، E، F، G، A، B، S (۸ توکن)

تغییر نتایج

با حذف علائم تغییردهنده:

- Perplexity کلی کاهش یافت؛ چون واژگان کوچک‌تر شد و مدل احتمال‌های بالاتری به هر توکن می‌دهد.
- الگوهای تکمیل برای Trigram کامل‌تر شدند (C B C D C B C D C B) که نشان‌دهنده تشخیص بهتر الگوهای تناوبی است.

- اما اطلاعات موسیقیایی مهمی از دست رفت — نت Bb و Ab در موسیقی شور بسیار مهم هستند و نادیده گرفتن آن‌ها ساختار دستگاه را مخدوش می‌کند.

Trigram بدون علائم — Laplace (α=۱):

قطعه	پیشوند داده شده	ادامه تولید شده	Perplexity
۱	S S S S	G S S G S S G S S G	۳.۸۴۶۲
۲	G C G C	C C C C C C C C C C	۳.۰۵۳۴
۳	C B C D	C B C D C B C D C B	۲.۹۰۵۷
۴	A B C D	C B C D C B C D C B	۳.۰۴۳۷
۵	A S B D	D C B C D C B C D C	۳.۵۵۳۷

۷. کدام قطعه ناقص خروجی بدتری دارد؟

در هر مدل، قطعه‌ای که Perplexity بالاتری دارد:

- **Unigram**: قطعه ۵ (A S B Db) — پیشوند شامل Db است که نادر است و Unigram زمینه را نادیده می‌گیرد.
- **Bigram**: قطعه ۵ Db — (A S B Db) به ندرت پس از B می‌آید، بنابراین bigram آخر زمینه ضعیفی دارد.
- **Trigram**: قطعه ۱ (S S S S) — زمینه S-S اطلاعات موسیقیایی کمی دارد و نت پس از سه سکوت متوالی نامشخص است.

دلیل: در تمام مدل‌ها، قطعاتی که پیشوندشان شامل نت‌های نادر یا ترکیبات ندیده‌شده است، Perplexity بالاتری دارند. این به خاطر sparsity است: مدل تجربه کمی از آن زمینه دارد.

۸. استفاده از ستون دستگاه

مزایای استفاده از اطلاعات دستگاه:

- هر دستگاه موسیقی ایرانی (شور، ماهور، دشتی، همایون، ...) مقام و مجموعه نت‌های خاص خود دارد. با آموزش مدل‌های جداگانه به ازای هر دستگاه، احتمالات به‌مراتب دقیق‌تر خواهند بود.
- می‌توان از دستگاه به عنوان یک ویژگی جانبی (side feature) استفاده کرد و احتمالات n-gram را با آن وزن‌دهی کرد.
- دستگاه به عنوان اطلاعات زمینه بلندمدت می‌تواند انتخاب‌های موسیقایی بلندتر از n توکن را راهنمایی کند.

مشکلات:

- بسیاری از قطعات دستگاه ندارند (مقدار '-'). این عدم تعادل در داده‌ها، استفاده از دستگاه را دشوار می‌سازد.

- با ۴۱ قطعه، تعداد نمونه به ازای هر دستگاه بسیار کم است (مثلاً فقط ۲ قطعه دشتی)، که منجر به مشکل data sparsity شدیدتر می‌شود.
- دستگاه قطعات ناقص نامشخص است؛ باید آن را از پیشوند استنتاج کرد که خود یک مسئله طبقه‌بندی جداگانه است.

۹. نتیجه‌گیری

در این تمرین، سه مدل زبانیN-gram (Unigram، Bigram، Trigram) با دو نوع هموارسازی Lidstone آموزش داده و ارزیابی شدند:

- Trigram با alpha=۰.۵ در اکثر موارد بهترین Perplexity را داشت — زمینه غنی‌تر، پیش‌بینی بهتر.
- Unigram با همه ترکیبات فقط C تولید کرد — نشان‌دهنده فقدان کامل مدل‌سازی زمینه.
- حذف علائم تغییردهنده Perplexity را کاهش داد اما اطلاعات موسیقیایی مهمی از بین برد.
- محدودیت اصلی: با تنها ۴۱ قطعه، مشکل sparsity در Trigram جدی است و مدل‌های عمیق‌تر نیاز به داده بیشتر دارند.